

European Health Data Space

Prototype d'Intégration de Données de Santé

Réalisateurs :

-Imad El Maftouhi -Salma Maaquili -Diae Khayati -Hamza Ait Youssef -Amina Louazir

Supervisée par : Pr. Baïda Ouafae

Plan

01

**CONTEXTE &
PROBLÉMATIQUE**

02

SOLUTION EHDS

03

**ARCHITECTURE
GLOBALE**

04

DATA LAKE

05

COUCHE SÉMANTIQUE

06

STANDARDS MÉDICAUX

07

**PIPELINE
D'INTÉGRATION**

08

PRINCIPES FAIR & CONFORMITÉ

09

DASHBOARD INTERACTIF



CONTEXTE & PROBLÉMATIQUE

Le Défi de l'Intégration des Données de Santé

Hôpital A	Laboratoire B	Clinique C
Format CSV	Format JSON	Format FHIR
Unités: mg/dL	Unités: µmol/L	Codes ICD-10
Système propriétaire	LOINC	HL7



- Hétérogénéité des formats
- Standards non uniformes
- Silos de données
- Qualité variable



SOURCES DE DONNÉES

MIMIC-III

- Format : CSV
- 120 patients
- source réelle

FHIR

- Format : JSON
- Dossiers médical
- Standards HL7


Laboratoire

- Format : JSON
- 600 résultats auto-généré

DICOM

- Format : DCM
- 150 études Auto-généré


SOLUTION EHDS



4 Piliers :

- **Data Lake:** Bronze → Silver → Gold
- **Sémantique:** RDF, SPARQL, Ontologies
- **Sécurité:** Pseudonymisation SHA-256
- **Standards:** FHIR, LOINC, ICD-10

ARCHITECTURE GLOBALE



- ✓ Séparation des préoccupations
- ✓ Évolutivité
- ✓ Conformité EHDS

DATA LAKE

Zone Bronze

Données Brutes

Caractéristiques

- Principe: Schema-on-read
- Format: Original (CSV, JSON, DICOM)
- Fonction: Préservation intégrale

Structure de dossiers

```
data/bronze/  
├─ ehr/      → PATIENTS.CSV  
├─ lab/      → lab_results.jso  
├─ fhir/     → bundle.ndjson  
└─ dicom/    → *.dcm
```

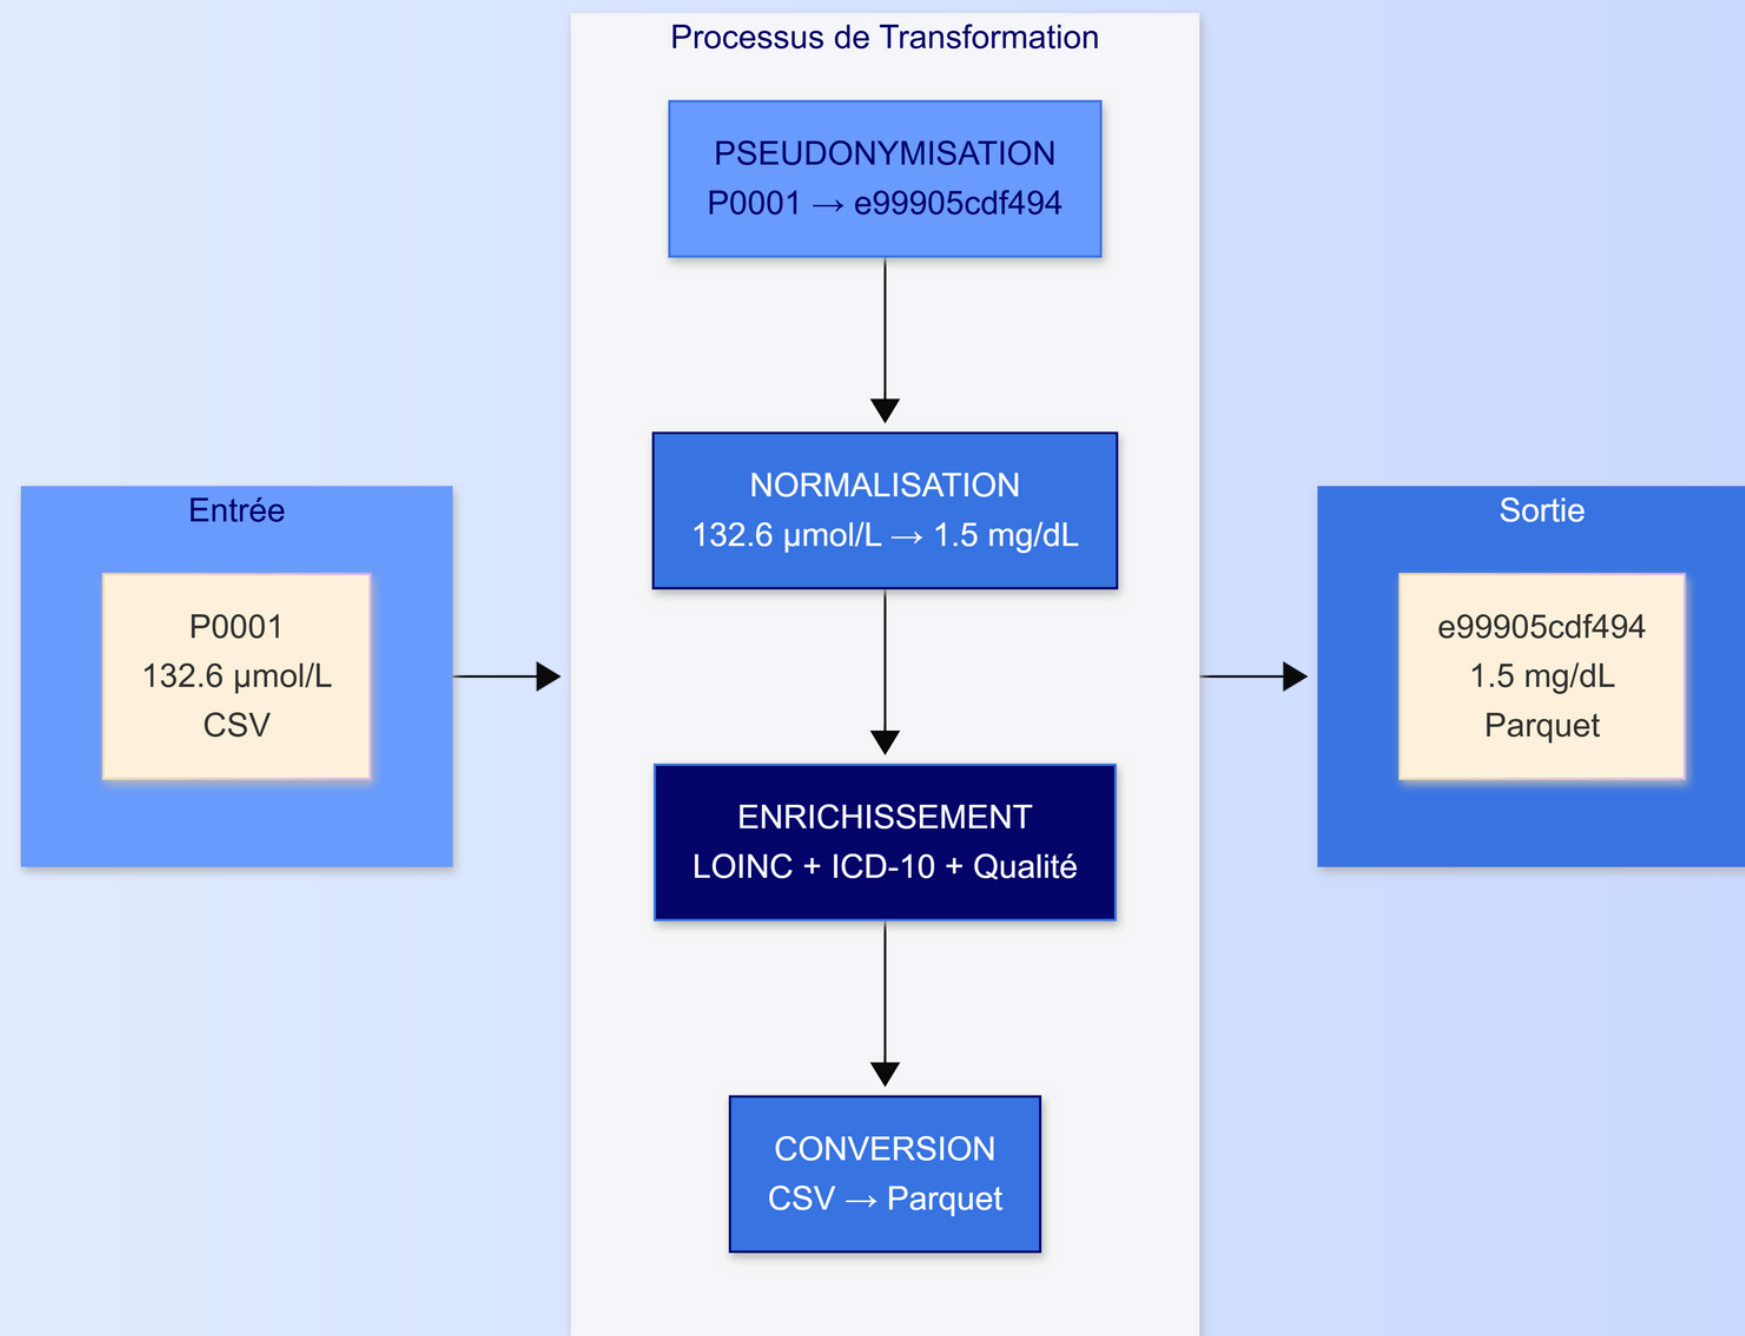
4 sources hétérogènes

~155 KB données Lab JSON

Aucune modification

Zone Silver

Enrichissement et Qualité



Bénéfices

- Sécurité RGPD
- Qualité garantie
- Performance optimisée

ZONE GOLD

Schéma Unifié

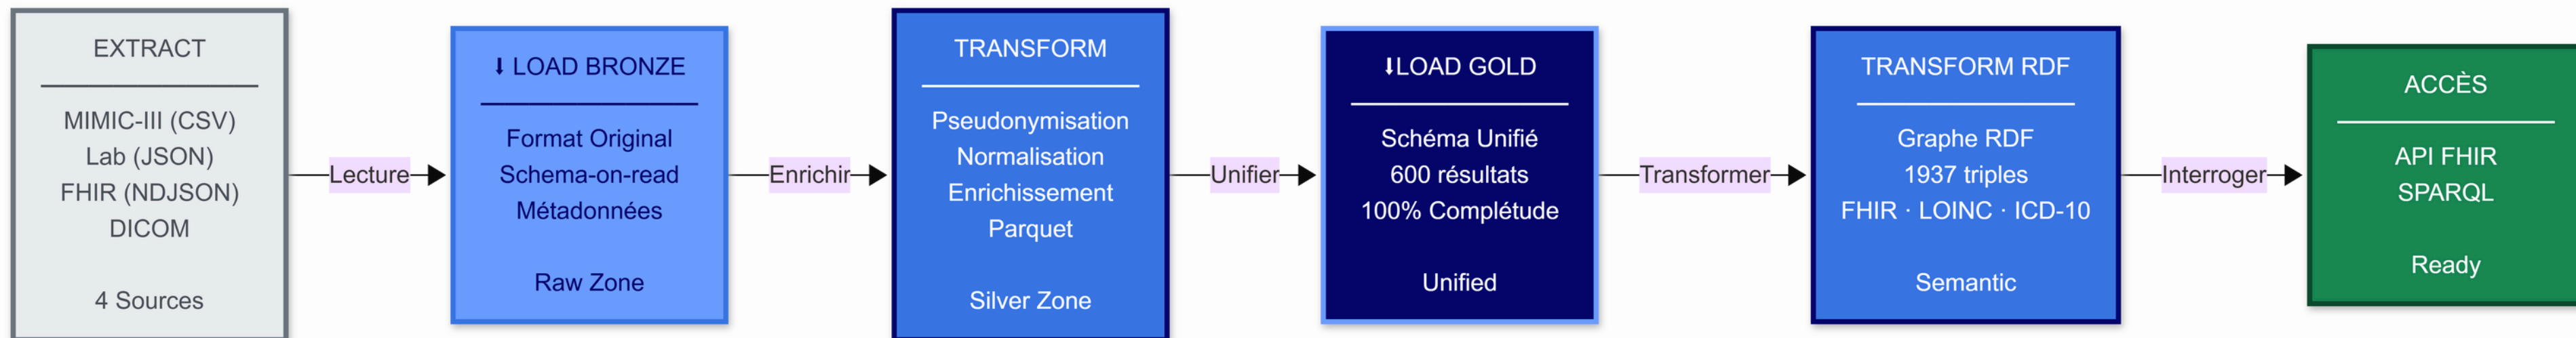
GOLD_UNIFIED_SCHEMA			
string	patient_id_pseudo	PK	SHA-256 hash
string	test_name		Nom du test
float	value		Valeur mesurée
string	unit		Unité (mg/dL, g/dL...)
date	date		Date du résultat
boolean	is_abnormal		Flag anomalie
string	icd10_code		Diagnostic
string	loinc_code		Code test LOINC

Bénéfices

- Prêt pour Analytics
- Compatible ML
- Qualité garantie
- Identifiants harmonisés


PIPELINE D'INTÉGRATION

Pipeline ELT Complet




PIPELINE D'INTÉGRATION

Pipeline ELT Complet



PIPELINE D'INTÉGRATION

Pipeline ELT Complet



PIPELINE D'INTÉGRATION

Pipeline ELT Complet

[STOCKAGE FINAL]

SQLite Database (6 tables)	+	RDF Graph (5000+ triplets)
data/integrated/ehds.db		data/semantic/ehds_data_graph.ttl

COUCHE SÉMANTIQUE

Catalogue Sémantique

Métadonnées Intelligentes



Ce que ça apporte:

- ✚ Localisation des datasets
- ✚ Traçabilité PROV-O
- ✚ Métriques qualité
- ✚ Lignage complet

```
data > semantic > catalog.ttl
1  @prefix catalog: <http://ehds.eu/catalog#> .
2  @prefix dct: <http://purl.org/dc/terms/> .
3  @prefix prov: <http://www.w3.org/ns/prov#> .
4  @prefix xsd: <http://www.w3.org/2001/XMLSchema#> .
5
6  <http://ehds.eu/catalog#dataset/ehds_unified_gold_20260113> a catalog:Dataset ;
7      catalog:format "parquet" ;
8      catalog:location "data\\gold\\ehds_unified.parquet" ;
9      catalog:rowCount 0 ;
10     catalog:zone "gold" .
11
12  <http://ehds.eu/catalog#dataset/lab_results_silver_20260113_230400> a catalog:Dataset ;
13     catalog:columnCount 14 ;
14     catalog:completeness "100.0"^^xsd:float ;
15     catalog:domain "lab" ;
16     catalog:format "parquet" ;
17     catalog:location "data\\silver\\lab\\lab_results_enriched.parquet" ;
18     catalog:rowCount 600 ;
19     catalog:sizeBytes 23446 ;
20     catalog:zone "silver" ;
21     dct:created "2026-01-13T23:04:00.897670"^^xsd:dateTime ;
22     prov:wasDerivedFrom <http://ehds.eu/catalog#dataset/lab_results_20260113_230400> .
23
```





GRAPHE RDF

Graphe de Connaissances RDF

Ontologies utilisées


- ✚ FHIR: <http://hl7.org/fhir/>
- ✚ LOINC: Codes tests labo
- ✚ ICD-10: Diagnostics
- ✚ SKOS: Vocabulaires



STANDARDS MÉDICAUX

Interopérabilité par les Standards

FHIR	LOINC
HL7 Fast Healthcare Interoperability Resources	Logical Observation Identifiers
Échange données médicales	Codes tests laboratoire
Ex: Patient, Observation	Ex: 718-7 = Hémoglobine



ICD-10	SKOS
Classification Internationale Maladies	Simple Knowledge Organization
Diagnostics standardisés	Vocabulaires contrôlés
Ex: E11 = Diabète type 2	Taxonomies hiérarchiques

PRINCIPES FAIR & CONFORMITÉ

FAIR

F - Findable

- ✓ Catalogue sémantique RDF
- ✓ Métadonnées standardisées

A - Accessible

- ✓ API SPARQL
- ✓ Zones clairement définies

I - Interoperable

- ✓ Standards: FHIR, LOINC, ICD-10
- ✓ RDF/OWL/SKOS

R - Reusable

- ✓ Données curées (Gold)
- ✓ Lignage PROV-O

Conformité RGPD:

- ✓ Pseudonymisation SHA-256
- ✓ Traçabilité complète

DASHBOARD INTERACTIF


Interface de Visualisation Streamlit

URL: [EHDS Data Integration](#)



COMPOSANTS

- Overview : Métriques système
- Data Lake Zones : Bronze/Silver/Gold
- Base Intégrée : Tables SQLite
- Qualité : Complétude, anomalies
- SPARQL : Requêtes interactives



TECHNOLOGIES

- Visaluation: Streamlit + Plotly
- Sémantique: RDFLib + SPARQL
- Données: Pandas + PyArrow/Parquet
- Imagerie: pydicom BASE: Python 3.10+

DÉMONSTRATION LIVE

Merci !